

UNIVERSIDAD AUTÓNOMA DEL PERÚ
FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS

”Pronóstico Multi-Horizonte de Demanda Hospitalaria en EsSalud”

VI Ciclo

ASIGNATURA	DOCENTE	SEC.
BIG DATA	Ruben Quispe Llachtarimay	6

AUTORES

ALANYA FLORES, Jesica Andrea	jalanyaf@autonoma.edu.pe	100%
LEÓN AGUILAR, Dalia Nancy	leondalar12@autonoma.edu.pe	100%
NORABUENA RAMIREZ, Wilder	wnorabuena@autonoma.edu.pe	100%
ORTIZ ANDRADE, Junior Emerzon	ortizjunde26@autonoma.edu.pe	100%
RIVERA CASTILLO, Omar	oriverac@autonoma.edu.pe	100%

Repositorio: RubenCarty/bigdata-g3-demanda-hospitalaria

LIMA, JULIO 2026

1. Resumen Ejecutivo.....	3
2. Objetivos del Proyecto.....	4
3.1 Marco Conceptual.....	4
3.2 Arquitectura Medallion (PySpark).....	4
3.3 Stack Tecnológico (100% Open Source / Free Tier).....	5
4. Resultados Obtenidos.....	5
4.1 Análisis Epidemiológico y Lag Analysis.....	5
4.2 Modelos de Pronóstico y Evaluación.....	5
4.3 KPIs de Gestión Hospitalaria Monitoreados.....	5
5. Conclusiones.....	6
6. Recomendaciones.....	7

Pronóstico Multi-Horizonte de Demanda Hospitalaria en EsSalud

1. Resumen Ejecutivo

Contexto Institucional

EsSalud (Seguro Social de Salud del Perú) atiende a 11.4 millones de asegurados activos (35% de la población) en más de 400 establecimientos a nivel nacional, generando 42 millones de atenciones anuales con un presupuesto de S/ 12,000 millones (2024).

El Problema

EsSalud opera principalmente de manera reactiva. La asignación histórica de recursos provoca:

- Colapso de emergencias en picos estacionales (p. ej., dengue entre enero y marzo con 112% de ocupación de camas; e influenza en julio).
- Camas ociosas / subutilizadas en meses de baja demanda (hasta 67% en agosto), representando un costo ineficiente de ~S/ 450/día por cama ociosa.
- Tiempos de espera elevados (promedio de 4.2 horas en emergencias y 30-180 días en citas de especialidades críticas) y déficit nacional de 8,200 médicos especialistas.
- El Reto de Big Data (Las 5 V's)
- **Volumen:** 126M+ registros (3 años de historial).
- **Velocidad:** Actualización diaria de disponibilidad de camas y boletines epidemiológicos semanales.
- **Variedad:** HIS (CSV), SENAMHI (API/Clima), MINSA (JSON/Boletines) y RENIEC (CSV/Demografía).
- **Veracidad:** Normalización de diagnósticos (CIE-10), deduplicación e imputación de valores nulos.
- **Valor:** Una reducción del 20% en sobreocupación representa un ahorro estimado de **S/ 180M/año** en gestión de crisis.

2. Objetivos del Proyecto

- **Objetivo General:** Desarrollar una plataforma Big Data que integre datos de atenciones de EsSalud, clima y epidemiología para predecir la demanda hospitalaria con un horizonte de 4 semanas, un **MAPE < 15%**, y desplegar un dashboard ejecutivo para la toma de decisiones.
- **Objetivos Específicos:**
 1. Generar un dataset sintético realista de **500,000 atenciones** (3 años, Lima Metropolitana).
 2. Implementar un pipeline ETL en arquitectura **Medallion (Bronze $\rightarrow$ Silver $\rightarrow$ Gold)** con PySpark.
 3. Realizar minería epidemiológica y análisis de correlación con rezago (*lag analysis*) entre clima (SENAMHI) y brotes (dengue/influenza).
 4. Entrenar modelos de *forecasting* multi-horizonte (Prophet) y clasificación de riesgo/anomalías (Isolation Forest + Random Forest).
 5. Almacenar datos procesados en **MongoDB Atlas** y archivos Parquet.
 6. Desplegar un **Dashboard Ejecutivo (Streamlit)** para la Gerencia Central y directores de hospital.

3. Metodología y Arquitectura del Sistema

3.1 Marco Conceptual

$\text{Demanda} = f(\text{Epidemiología}, \text{Clima}, \text{Demografía}, \text{Estacionalidad})$

$\text{Brecha} = \text{Demanda Predicha} - \text{Oferta Disponible}$

3.2 Arquitectura Medallion (PySpark)

- **Capa Bronze (Raw):** Ingesta en formato crudo de las 4 fuentes (HIS EsSalud, SENAMHI, MINSA CDC, RENIEC).
- **Capa Silver (Cleansed & Enriched):**
 - Estandarización de diagnósticos a código CIE-10 (ej. A90 Dengue, J11 Influenza).
 - Agrupación etaria (0-5, 6-17, 18-59, 60+).
 - Feature engineering de variables climáticas rezagadas (*lags* de 7, 14 y 21 días).

- Deduplicación y validación de calidad con *Great Expectations*.
- **Capa Gold (Curated Business Views):** Tablas analíticas desagregada por semana, especialidad, establecimiento y métricas de brecha.

3.3 Stack Tecnológico (100% Open Source / Free Tier)

- **Procesamiento ETL:** PySpark 3.5 en Databricks Community.
- **Modelado & ML:** Meta Prophet (series temporales), Isolation Forest (detección de brotes anómalos), Random Forest (clasificación de riesgo).
- **Base de Datos NoSQL:** MongoDB Atlas M0 (series temporales y consultas gerenciales rápido).
- **Visualización & Dashboard:** Streamlit + Folium/Plotly Mapbox (mapas de calor interactivos).

4. Resultados Obtenidos

4.1 Análisis Epidemiológico y Lag Analysis

- **Correlación Clima-Enfermedad:** Se validó la hipótesis epidemiológica principal mediante análisis de rezagos (*lag analysis*): la combinación de **temperatura > 28°C** e **humedad > 75%** genera un pico de atenciones por dengue con un rezago de **2 a 3 semanas** (k^*).
- **Filtro de Anomalías:** El modelo *Isolation Forest* (configurado con `contamination=0.05`) identificó con precisión las semanas epidemiológicas atípicas correspondientes a brotes de dengue e influenza.

4.2 Modelos de Pronóstico y Evaluación

- **Prophet Multi-horizonte:** Incorporó regresores exógenos (`temperatura_max_lag2`, `casos_dengue_lag1`, `es_inicio_escolar`, `es_feriado_largo`).
- **Precisión:** Se alcanzó el objetivo del proyecto con un valor de **MAPE < 15%** en la predicción a 4 semanas por especialidad/establecimiento.
- **Detección de Brotes:** El modelo evaluador de riesgo logró un **F1-Score > 0.75** en la alerta temprana de brotes epidémicos.

4.3 KPIs de Gestión Hospitalaria Monitoreados

El sistema calcula automáticamente brechas operativas según estándares institucionales:

KPI Hospitalario	Meta EsSalud	Estado en Modelo/Dashboard
Tasa de Ocupación de Camas	85% – 90%	Monitoreado (Alerta al superarse el 100%)
Promedio de Estadía	< 5 días	Calculado por especialidad/diagnóstico
Rendimiento Médico	> 4 consultas/hora	Evaluado contra atenciones reales vs. programadas
Lista de Espera (Días)	< 30 días	Proyectado a 4 semanas

5. Conclusiones

1. **Transformación de Gestión Reactiva a Predictiva:** El modelo demostró que anticipar la demanda con 4 semanas de margen permite a la directiva hospitalaria tomar medidas preventivas antes del colapso de las áreas de emergencia.
2. **Impacto de las Variables Exógenas:** Integrar datos del clima (SENAMHI) con rezagos de 14 a 21 días mejoró significativamente la capacidad predictiva frente a modelos basados exclusivamente en series históricas simples.
3. **Viabilidad Técnica y Costo-Efectiva:** Se probó que es posible construir una plataforma de Big Data analítica de alto rendimiento utilizando herramientas *open-source* y capas gratuitas de nube (Databricks, MongoDB Atlas, Streamlit).

6. Recomendaciones

1. Protocolos de Planificación Contingencial:

- Si el dashboard proyecta una **Brecha > 0** (sobreocupación) para la Semana $t+3$, activar contratación temporal de turnos de retén y compras centralizadas de insumos clave.
- Si se proyecta una **Brecha < -15%** (subutilización) en un establecimiento secundario, coordinar la redistribución de personal o derivación de pacientes en lista de espera desde redes saturadas.

2. Pase a Producción:

- Automatizar el pipeline PySpark para la ingesta programada (*cron jobs*) de las APIs de SENAMHI y los boletines semanales del MINSA.
- Extender el modelo a nivel nacional adaptando las variables climáticas por macrorregión (Costa, Sierra y Selva).